3 相関係数

共分散は，データの単位や尺度を変えると値が変わるため，その数値だけで関係の強さを比較しにくい．そこで，標準偏差 s_x, s_y を用いて尺度の影響を取り除く．

$s_x > 0$ かつ $s_y > 0$ のとき，次の量を**相関係数** $r = r_{xy}$ という：

$$\boxed{r = \frac{c_{xy}}{s_x s_y}} = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{x_i - \bar{x}}{s_x}\right)\left(\frac{y_i - \bar{y}}{s_y}\right).$$

つまり，**両方の変数を標準化した後の共分散**である．Y を正の定数 a 倍すると，共分散も s_y も a 倍になるので，r は変わらない．

相関係数の範囲は

$$\boxed{-1 \le r \le 1}.$$

r の符号は相関の向きを，絶対値 $|r|$ は**直線的な関係の強さ**を表す．

(1) $r = 1$ なら全点が右上がりの 1 本の直線上に，$r = -1$ なら全点が右下がりの 1 本の直線上にある．

(2) 逆も成り立つ．

$r = 0$ のときを**無相関**という．

範囲の証明．標準化した値を $u_i = (x_i - \bar{x})/s_x$，$w_i = (y_i - \bar{y})/s_y$ とおくと，

$$\frac{1}{n}\sum_{i=1}^{n}(u_i \pm w_i)^2 = 1 \pm 2r + 1 = 2 \pm 2r \ge 0.$$

よって，$2 + 2r \ge 0$ かつ $2 - 2r \ge 0$ より，$-1 \le r \le 1$． □

【例 3】 データ A の相関係数を求める．前節の表から，

$$v_x = \frac{56}{6} = \frac{28}{3}, \qquad v_y = \frac{56}{6} = \frac{28}{3}, \qquad c_{xy} = 7$$

であるから，$s_x = s_y = \sqrt{28/3}$ である．したがって，

$$r = \frac{7}{\sqrt{28/3}\cdot\sqrt{28/3}} = \boxed{\frac{3}{4} = 0.75}.$$

正の直線的な関係が見られるが，すべての点が 1 本の直線上にあるわけではない．

【演習 3】 データ B の相関係数を求め，データ A と相関の向き・強さを比較せよ．

$v_x =$ 9.33　　$v_y =$ 9.33　　$c_{xy} =$ -4.67

$$r = \frac{-4.67}{\sqrt{9.33}\cdot\sqrt{9.33}} = -0.5$$

データ B の相関：

データ A との比較：

注意

- 無相関は「関係がない」という意味ではない．例えば，

  $$(x_i, y_i) = (-1, 1),\ (0, 0),\ (1, 1)$$

  では，$\bar{x} = 0$，$\bar{y} = 2/3$ であり，$c_{xy} = 0$，$r = 0$ となるが，$y_i = x_i^2$ という関係がある．
- 相関があっても，片方がもう片方の原因であるとは限らない．