4 回帰直線

X から Y のおよその値を予測するため，散布図に直線を当てはめる．このとき，X を**説明変数**，Y を**目的変数**という．直線を $\widehat{y} = ax + b$ とすると，x_i に対する**予測値**は $\widehat{y}_i = ax_i + b$ である．観測値と予測値との差

$$e_i = y_i - \widehat{y}_i = y_i - (ax_i + b)$$

を**残差**という．**縦方向のずれである残差の 2 乗の和**

$$Q(a,b) = \sum_{i=1}^{n} \{y_i - (ax_i + b)\}^2$$

を最小にする方法を**最小二乗法**といい，それによって定まる直線を **Y の X への回帰直線**という．

$v_x > 0$ のとき，傾き a と切片 b は一意に定まり，

$$\boxed{a = \frac{c_{xy}}{v_x}, \qquad b = \bar{y} - a\bar{x}} \qquad (s_y > 0 \text{ なら } a = r\frac{s_y}{s_x}).$$

したがって，回帰直線は必ず点 $(\bar{x}, \bar{y})$ を通る．

証明. $y_i - ax_i - b = (y_i - \bar{y}) - a(x_i - \bar{x}) + (\bar{y} - a\bar{x} - b)$ を 2 乗して平均すると，偏差の和 $= \sum_i (x_i - \bar{x}) = \sum_i (y_i - \bar{y}) = 0$ であることから，

$$\begin{aligned} \frac{Q(a,b)}{n} &= v_y - 2ac_{xy} + a^2 v_x + (\bar{y} - a\bar{x} - b)^2 \\ &= v_x \left(a - \frac{c_{xy}}{v_x}\right)^2 + (\bar{y} - a\bar{x} - b)^2 + v_y - \frac{c_{xy}^2}{v_x}. \end{aligned}$$

最後の項は a, b に依存しないので，2 つの平方の項をともに 0 にすればよい． □

【例 4】 データ A の回帰直線と，$x = 7$ のときの予測値・残差を求める．

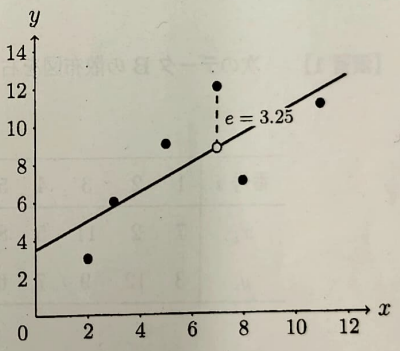
$\bar{x} = 6$, $\bar{y} = 8$, $v_x = 28/3$, $c_{xy} = 7$ より，

$$a = \frac{7}{28/3} = \frac{3}{4}, \qquad b = 8 - \frac{3}{4} \cdot 6 = \frac{7}{2}.$$

したがって，回帰直線は

$$\boxed{\widehat{y} = \frac{3}{4}x + \frac{7}{2}}.$$

$x = 7$ のとき，予測値は $\widehat{y} = 35/4 = 8.75$．観測値は $y = 12$ なので，残差は $e = 12 - 8.75 = 3.25$ となる．



【演習 4】 データ B の Y の X への回帰直線を求めよ．また，$x = 7$ のときの予測値と，その観測値 $y = 3$ に対する残差を求めよ．

注意 観測した x の範囲から大きく外れた値への予測や，散布図が曲線状なのに直線で予測することには注意が必要である．

A と B の和事象 $A \cup B = \{2,3,4,5,6\}$.