確率統計 I 第 1 回
度数分布表，ヒストグラム，代表値

以下は，あるクラス 40 名が受験した「工学基礎数学」のテスト（100 点満点）のデータである．

データ（40 人分）

65, 52, 45, 72, 58, 91, 68, 67, 53, 55, 61, 74, 49, 69, 66, 88, 71, 55, 84, 63,
76, 59, 94, 69, 73, 51, 80, 64. 78, 56, 89, 62, 75, 48, 81, 67, 70, 57, 86, 60

【状況】あなたの点数は「72 点」であった．

【問い】 あなたはクラスの中でおよそどのような位置付けだろうか．

1 代表値

データ $x_1, \ldots, x_n$ 全体の傾向や特徴を 1 つの数値で代表して表したものを**代表値**という．

- **平均値** $\bar{x}$：データの総和をデータの個数 n で割ったもの：

  $\bar{x} =$ データの個数 $\times \sum$ 各データ

  $= \frac{1}{n} \sum_{i=1}^{n} x_i$

  – 例：$3, 2, 5, 1, 7 \rightarrow \dfrac{3+2+5+1+7}{5} = 3.6$

- **メディアン（中央値）** Me: データを昇順 $y_1 \leq y_2 \leq \cdots \leq y_n$ に並べ直したときの真ん中の値．真ん中の数が 2 つある場合 (n が偶数) のときは真ん中の 2 つの平均：

  – 例：$3, 2, 5, 1, 7 \rightarrow 1, 2, \underline{3}, 5, 7 \rightarrow 3$

  – 例：$3, 2, 5, 1, 7, 9 \rightarrow 1, 2, \underline{3, 5}, 7, 9 \rightarrow \dfrac{3+5}{2} = 4$

【演習 1】（個々のデータからの平均値とメディアンの算出）

1) 5 人分の小テストデータ（68, 74, 82, 55, 91）の平均値・中央値を求めよ．

（解答） 平均値 $\bar{x} = (68+74+82+55+91) \div 5 = 74$

中央値 $Me = 74$

2) 冒頭の 40 人データの合計は 2701 点である．平均値 $\bar{x}$ を求めよ．

（解答） $\bar{x} = 2701 \div 40 = 69.525$

3) 40 人データを昇順に並べ替えたとき，20 番目は 67 点，21 番目は 67 点であった．メディアン Me を求めよ．

（解答） $Me = 67$

2 データの整理と可視化（度数分布表とヒストグラム）

データを適切な区間（グループ）に区切って整理することで，全体の中での位置付けを読み取りやすくする．

【例】

66, 60, 59, 61, 77, 65, 71, 70

階級	階級値	度数	相対度数	累積度数	累積相対度数
50 以上 ～ 59 以下	54.5	1	0.125	1	0.125
60 ～ 69	64.5	4	0.5	5	0.625
70 ～ 80	74.5	3	0.475	8	1
合計	—	8	1.000	—	—

- **階級**：データの区切りのこと．
- **階級値**：階級内の値を満遍なくとった場合の平均．
- **度数**：その階級に属するデータの数
- **相対度数**：その階級に属するデータの割合 $= \dfrac{\text{度数}}{\text{データ数}}$
- **累積度数**：その階級以下の全ての階級の度数の和
- **累積相対度数**：相対度数の累積度数．あるいは同じものだが，累積度数の相対度数．

【演習 2】（40 人データの度数分布表と位置付けの特定）

冒頭の 40 人データを 10 点刻みで整理した以下の度数分布表を完成させよ．72 点であるあなたは上位およそ何 % に属するか．

階級（点）	階級値 (x_i)	度数 (f_i)	相対度数	累積度数（人）	累積相対度数
40 以上 ～ 49 以下	44.5	3	0.075	3	0.075
50 以上 ～ 59 以下	54.5	9	0.225	12	0.300
60 以上 ～ 69 以下	64.5	12	0.3	24	0.6
70 以上 ～ 79 以下	74.5	8	0.2	32	0.8
80 以上 ～ 89 以下	84.5	6	0.15	38	0.95
90 以上 ～ 99 以下	94.5	2	0.05	40	1
合計	—	40	1	—	—

【変数の種類】

- **連続型変数**：(理想的には) ある区間のどんな実数もとりうる変数．身長，体重，速さなど．
- **離散型変数**：1 刻みや 0.5 刻みなど，最小単位のある変数．テストの点数，人数，文字数など．
- **質的変数（カテゴリ変数）**：大小関係が考慮されない変数．血液型，誕生月，MBTI 診断の結果など．
- **量的変数**：大小関係が考慮される変数．温度，身長，高さなど．

【演習 3】（スマホ利用時間データの度数分布表作成）

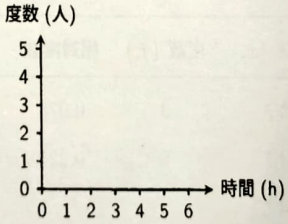
以下の 14 人の利用時間データ（時間）について，1.0 時間刻み・6 階級の度数分布表を完成させよ．

1 日のスマホ利用時間データ（14 人分・時間）

0.2, 0.4, 0.7, 0.8, 1.2, 1.8, 2.5, 3.1, 3.6, 4.1, 4.5, 4.8, 5.2, 5.6

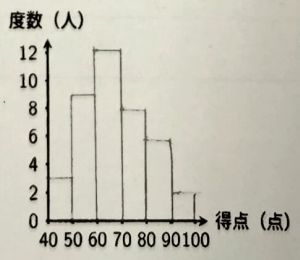
階級（時間）	階級値 (x_i)	度数 (f_i)	相対度数
0.0 以上 ～ 1.0 未満	0.5	4	0.286
1.0 以上 ～ 2.0 未満	1.5	2	0.143
2.0 以上 ～ 3.0 未満	2.5		
3.0 以上 ～ 4.0 未満	3.5		
4.0 以上 ～ 5.0 未満	4.5		
5.0 以上 ～ 6.0 未満	5.5		
合計	—		

【ヒストグラム】この階級度数分布表に基づいてヒストグラムを描いてみよう．



【演習 4】（ヒストグラムの描画）

演習 2 の度数分布表（40 人データ）をもとに，ヒストグラムを描け．



3 度数分布表からの代表値の近似

元の個別データが手元になく度数分布表しか与えられていない場合，**各データはその階級の階級値をとるとみなして代表値を近似する．**例えば，10 以上 19 以下の階級の度数が 5 の時，本当のデータは 10, 10, 11, 12, 14 かもしれないし，18, 19, 19, 19, 19 かもしれないが，これを 14.5, 14.5, 14.5, 14.5, 14.5 とみなして近似する．この近似は多くの場合，度数が大きくなるほど，精度が良くなる．

この方針により，例えば階級値 $x_1, x_2, \ldots, x_i, \ldots, x_N$ の度数がそれぞれ $f_1, f_2, \ldots, f_i, \ldots, f_N$ の時 (N は階級の個数であって，データの個数ではないことに注意)，

- **平均値の近似**：データは全てそのデータが属する階級の階級値を取るとして計算．
- **メディアンの近似**：初めて累積度数がデータ数の半数以上になる階級の階級値．同じことだが，初めて累積相対度数が 0.5 以上になる階級の階級値．
- **モード（最頻値）**：度数が最大の階級値．

【例】

階級（時間）	階級値 (x_i)	度数 (f_i)	相対度数	累積相対度数
0.0 以上 ～ 1.0 未満	0.5	1	0.04	0.04
1.0 ～ 2.0	1.5	4	0.16	0.20
2.0 ～ 3.0	2.5	8	0.32	0.52
3.0 ～ 4.0	3.5	9	0.36	0.88
4.0 ～ 5.0	4.5	2	0.08	0.96
5.0 ～ 6.0	5.5	1	0.04	1.00
合計	—	25	1.00	—

1. **平均値の近似値：** 2.9

2. **メディアンの近似値：** 2.5

3. **モード：** 3.5

【演習 5】（40 人データの度数分布表からの代表値算出）
演習 2 の度数分布表のみを用いて，以下の代表値を求めよ．

1. **平均値の近似値：** 69.25

2. **メディアンの近似値：** 64.5

3. **モード：** 64.5

4 第 1 回確認問題

【演習 6】（総合演習 1：離散型変数・テストの点数）

以下は，ある実験班 20 名が受験した小テスト（100 点満点）のデータである．

小テストデータ（20 人分）

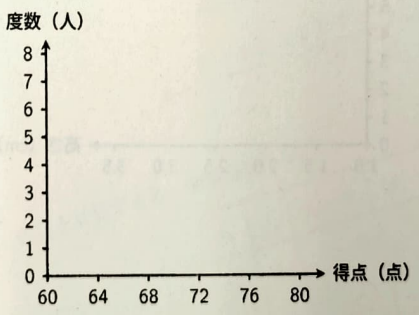
70, 65, 71, 68, 74, 62, 77, 69, 73, 71, 66, 70, 75, 64, 69, 78, 67, 72, 61, 74

1. 4 点刻み・5 階級（「60 以上 ～ 63 以下」，…）の階級度数分布表（階級値，度数，相対度数，累積度数）を完成させ，その度数分布表をもとにヒストグラムを描け．
2. 度数分布表を用いて，平均値の近似値，メディアンの近似値，モード（最頻値）を求めよ．

1.1 階級度数分布表

階級（点）	階級値 (x_i)	度数 (f_i)	相対度数	累積度数（人）
60 以上 ～ 63 以下				
64 以上 ～ 67 以下				
68 以上 ～ 71 以下				
72 以上 ～ 75 以下				
76 以上 ～ 79 以下				
合計	—			—

1.2 ヒストグラム



2. 代表値

- 平均値（近似値）：
- メディアン（近似値）：
- モード（最頻値）：

【演習 7】（総合演習 2：連続型変数・小数の連続データ）

以下は，ある温室で栽培された植物の苗 20 本の高さ（cm）を測定したデータである．

苗の高さデータ（20 本分・cm）

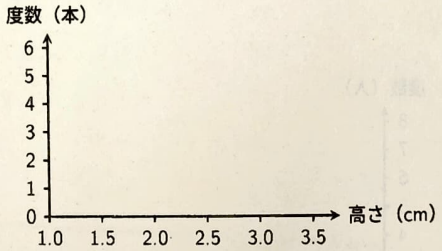
1.1, 1.3, 1.4, 1.6, 1.7, 1.8, 1.9, 2.1, 2.2, 2.3,
2.4, 2.4, 2.6, 2.7, 2.8, 2.9, 3.1, 3.2, 3.3, 3.4

1. 0.5 cm 刻み・5 階級（「1.0 以上 ～ 1.5 未満」，…）の階級度数分布表（階級値，度数，相対度数，累積度数）を完成させ，その度数分布表をもとにヒストグラムを描け．
2. 度数分布表を用いて，平均値の近似値，メディアンの近似値，モード（最頻値）を求めよ．

1.1 階級度数分布表

階級（cm）	階級値 (x_i)	度数 (f_i)	相対度数	累積度数（本）
1.0 以上 ～ 1.5 未満				
1.5 ～ 2.0				
2.0 ～ 2.5				
2.5 ～ 3.0				
3.0 ～ 3.5				
合計	—			—

1.2 ヒストグラム



2. 代表値

- 平均値（近似値）：

- メディアン（近似値）：

- モード（最頻値）：

確率統計 I 第 2 回
分散と標準偏差

代表値（平均・メディアン・モード）は，データのおよその傾向を表す値である．今回は，データのばらつきを表す値を見ていく．

データ $x_1, \ldots, x_n$ について，次の量を定める．

1 レンジ・分散・標準偏差

レンジ R　データの最大値から最小値を引いたもの：

$$R = (\text{最大値}) - (\text{最小値}).$$

分散 v_x　各データの平均との差の 2 乗の平均：

$$v_x = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2.$$

標準偏差 s_x　分散の正の平方根：

$$s_x = \sqrt{v_x}.$$

【例 1】

次の度数分布表で表されるデータのレンジ，分散，標準偏差を求める．

値 x_i	2	4	5	7	9	計
度数 f_i	1	3	2	1	1	8

まず，平均は

$$\bar{x} = \frac{2\cdot 1 + 4\cdot 3 + 5\cdot 2 + 7\cdot 1 + 9\cdot 1}{8} = \frac{40}{8} = 5$$

である．

各値の平均との差を計算すると，次の表を得る．

x_i	f_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$	$f_i(x_i - \bar{x})^2$
2	1	-3	9	9
4	3	-1	1	3
5	2	0	0	0
7	1	2	4	4
9	1	4	16	16
計	8			32

よって，

$$\text{レンジ：}\quad R = 9 - 2 = 7,$$

$$\text{分散：}\quad v_x = \frac{1}{8}\times 32 = 4,$$

$$\text{標準偏差：}\quad s_x = \sqrt{v_x} = \sqrt{4} = 2.$$

【演習 1】

次の度数分布表で表されるデータのレンジ，分散，標準偏差を求めよ．

値 x_i	3	5	6	8	10	計
度数 f_i	1	3	2	1	1	8

平均は

$$\bar{x} = 6$$

である.

各値について，平均との差およびその 2 乗を求め，次の表を完成させよ.

x_i	f_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$	$f_i(x_i - \bar{x})^2$
3	1	-3	9	9
5	3	-1	1	3
6	2	0	0	0
8	1	2	4	4
10	1	4	16	16
計	8	2	30	32

よって,

レンジ： 9

分散： 4

標準偏差： 2

2 分散と平均の関係

データ $x_1, \ldots, x_n$ の平均 $\bar{x}$ と分散 v_x には次の関係がある：

$$v_x = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}^2 \tag{1}$$

即ち,

$$(\text{分散}) = (2\text{ 乗の平均}) - (\text{平均の 2 乗}) \tag{2}$$

Proof.

$$\begin{aligned}
v_x &= \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})^2 \\
&= \frac{1}{n}\sum_{i=1}^{n}(x_i^2 - 2x_i\overline{x} + \overline{x}^2) \\
&= \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \frac{1}{n}\sum_{i=1}^{n} 2x_i\overline{x} + \frac{1}{n}\sum_{i=1}^{n}\overline{x}^2 \\
&= \frac{1}{n}\sum_{i=1}^{n} x_i^2 - 2\overline{x}\cdot\frac{1}{n}\sum_{i=1}^{n} x_i + \frac{1}{n}\cdot n\overline{x}^2 \\
&= \frac{1}{n}\sum_{i=1}^{n} x_i^2 - 2\overline{x}^2 + \overline{x}^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \overline{x}^2
\end{aligned}$$

□

また，度数分布表において $x_1, \ldots, x_N$ の度数がそれぞれ $f_1, \ldots, f_N$ の時,

$$v_x = \frac{1}{n}\sum_{i=1}^{n} f_i x_i^2 - \bar{x}^2 \tag{3}$$

【例 2】　次の度数分布表で表されるデータの分散を，

$$v_x = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}^2$$

を用いて求める．

値 x_i	2	4	5	7	9	計
度数 f_i	1	3	2	1	1	8

まず，平均は

$$\bar{x} = \frac{2\cdot 1 + 4\cdot 3 + 5\cdot 2 + 7\cdot 1 + 9\cdot 1}{8} = 5$$

である．

また，2 乗の平均は

$$\frac{1}{8}\left(2^2\cdot 1 + 4^2\cdot 3 + 5^2\cdot 2 + 7^2\cdot 1 + 9^2\cdot 1\right) = \frac{232}{8} = 29$$

である．

したがって，

$$v_x = 29 - 5^2 = 4$$

である．

【演習 2】　次の度数分布表で表されるデータの分散を，

$$v_x = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}^2$$

を用いて求めよ．

値 x_i	3	5	6	8	10	計
度数 f_i	1	3	2	1	1	8

$\overline{x} = \frac{3+5\cdot 3+6\cdot 2+8+10}{8} = 6$

$\overline{x^2} = \frac{1}{8}(9+25\times 3+36\times 2+64+100) = 40$

$\therefore v_x = \overline{x^2} - \overline{x}^2 = 4$

62, 69, 64, 66, 65, 61

$\overline{x}^2 = \frac{449225}{36} = 4117\frac{13}{36}$

$v_x = \frac{161}{36} = 4\frac{17}{36}$

$\overline{x^2} = \frac{24731}{6} = 4121\frac{5}{6}$

3 一次変換の平均・分散・標準偏差

変数 X が $x_1, \ldots, x_n$ の時，$f(x_1), \ldots, f(x_n)$ をとる変数を $f(X)$ とかく．特に，a, b を定数とするとき，変数 $aX+b$ のとる値は $ax_1+b, \ldots, ax_n+b$ である．

変数 X の平均，分散，標準偏差をそれぞれ $\bar{x}, v_x, s_x$ とすると一次変換 $Y = aX + b$ $(y_1, \ldots, y_n)$ について次が成り立つ：

$$\text{平均：} \quad \bar{y} = a\bar{x} + b, \tag{4}$$

$$\text{分散：} \quad v_y = a^2 v_x, \tag{5}$$

$$\text{標準偏差：} \quad s_y = |a| s_x. \tag{6}$$

すなわち，すべてのデータに同じ値 b を加えても分散・標準偏差は変化せず，すべてのデータを a 倍すると，分散は a^2 倍，標準偏差は $|a|$ 倍になる．

Proof.

平均

$$\begin{aligned}\bar{y} &= \frac{1}{n}\sum_{i=1}^{n}(ax_i+b)\\ &= a\frac{1}{n}\sum_{i=1}^{n}x_i + b\\ &= a\bar{x} + b.\end{aligned}$$

分散

$$\begin{aligned}v_y &= \frac{1}{n}\sum_{i=1}^{n}\{(ax_i+b)-(a\bar{x}+b)\}^2\\ &= \frac{1}{n}\sum_{i=1}^{n}\{a(x_i-\bar{x})\}^2\\ &= a^2\frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})^2\\ &= a^2 v_x.\end{aligned}$$

標準偏差

$$\begin{aligned}s_y &= \sqrt{v_y}\\ &= \sqrt{a^2 v_x}\\ &= |a|\sqrt{v_x}\\ &= |a| s_x.\end{aligned}$$

□

変数 X の平均を $\bar{x}$, 標準偏差を s_x とおく．

【例 3】

$$Z = \frac{X-\bar{x}}{s_x}$$

とした時，平均 Z の平均 $\bar{z}$ は 0, 標準偏差 s_z は 1 となる．この変換を**標準化**という．

【演習 3】 次の変数を**偏差値**という．

$$T = 50 + 10 \cdot \frac{X-\bar{x}}{s_x}$$

偏差値の平均 $\bar{t}$, 標準偏差 s_t を求めよ．また，平均点が 68 点，標準偏差が 12 点の試験で 74 点を取った時の偏差値を求めよ．

$\bar{t} = 50$

$s_t = 10$

$\frac{74-68}{12} = 0.5$

$50 + 10 \times 0.5 = 55$

確率統計 I 第 3 回
散布図・共分散・相関係数・回帰直線

1 散布図

同じ人について数学と物理の得点を調べるように，1 つの観測対象について 2 つの値を記録したデータを **2 次元データ**という．変数を X, Y とし，n 組のデータを

$$(x_1, y_1),\ (x_2, y_2),\ \ldots,\ (x_n, y_n)$$

と表す．x_i と y_i は，**同じ観測対象についての値**である．例： 人間 i の身長 x_i と体重 y_i.

横軸を X，縦軸を Y として，各組 (x_i, y_i) を平面上の点として表した図を**散布図**という．

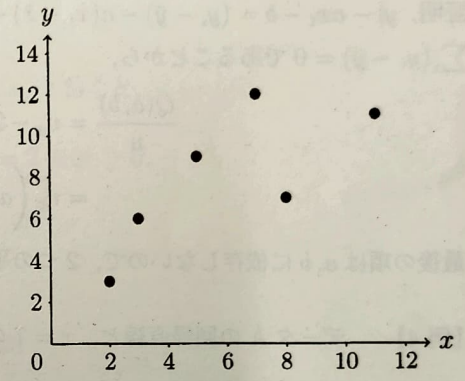
正の相関　x が大きいほど y も直線的に大きくなる傾向（右上がりの傾向）.

負の相関　x が大きいほど y は直線的に小さくなる傾向（右下がりの傾向）.

【例 1】　次の**データ A** の散布図を描く．

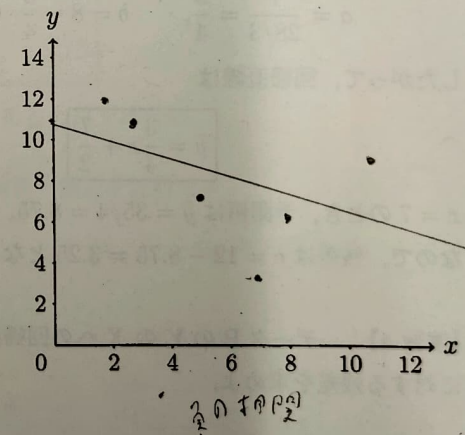
番号 i	1	2	3	4	5	6
x_i	7	2	11	5	8	3
y_i	12	3	11	9	7	6

例えば，番号 1 のデータは点 $(7, 12)$ として表す．同様に 6 個の点を打つと，右の図になる．全体として右上がりであり，正の相関が見られる．



【演習 1】　次の**データ B** の散布図を右の座標平面に描き，どのような相関が見られるか答えよ．

番号 i	1	2	3	4	5	6
x_i	7	2	11	5	8	3
y_i	3	12	9	7	6	11



2 共分散

X, Y の平均をそれぞれ $\bar{x}, \bar{y}$ とする．平均との差 $x_i - \bar{x}$，$y_i - \bar{y}$ を，それぞれの**偏差**という．**2 つの偏差の積の平均**を**共分散**といい，c_{xy} または $\mathrm{Cov}[X, Y]$ で表す：

$$\boxed{c_{xy} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})} \qquad \left(= \frac{1}{n}\sum_{i=1}^{n} x_i y_i - \bar{x}\bar{y}\right).$$

偏差の積は，同じ向きのずれなら正，逆向きなら負となる．共分散は，**ずれの向きと大きさ**の両方を反映する．

【例 2】 データ A の平均・偏差を計算し，共分散を求める．

$$\bar{x} = \frac{7+2+11+5+8+3}{6} = 6, \qquad \bar{y} = \frac{12+3+11+9+7+6}{6} = 8$$

x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$	$(x_i - \bar{x})(y_i - \bar{y})$
7	12	1	4	1	16	4
2	3	−4	−5	16	25	20
11	11	5	3	25	9	15
5	9	−1	1	1	1	−1
8	7	2	−1	4	1	−2
3	6	−3	−2	9	4	6
計	—	0	0	56	56	42

したがって，共分散は

$$c_{xy} = \frac{4+20+15-1-2+6}{6} = \boxed{7}.$$

【演習 2】 データ B について，平均を求め，次の表を完成させて共分散を求めよ．

平均： $\bar{x} = 6$ $\bar{y} = 8$.

x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$	$(x_i - \bar{x})(y_i - \bar{y})$
7	3	1	-5	1	25	-5
2	12	-4	4	16	16	-16
11	9	5	1	25	1	5
5	7	-1	-1	1	1	1
8	6	2	-2	4	4	-4
3	11	-3	3	9	9	-9
計	—	0	0	56	56	-28

$$c_{xy} = -4.67$$

分散とのつながり 自分自身との共分散は分散である（$s_{xx} = v_x$）．また，$z_i = x_i + y_i$ とおくと $\boxed{v_z = v_x + v_y + 2c_{xy}}$ であり，共分散は和のばらつきの強め合い・打ち消し合いを表す．

3 相関係数

共分散は，データの単位や尺度を変えると値が変わるため，その数値だけで関係の強さを比較しにくい．そこで，標準偏差 s_x, s_y を用いて尺度の影響を取り除く．

$s_x > 0$ かつ $s_y > 0$ のとき，次の量を**相関係数** $r = r_{xy}$ という：

$$\boxed{r = \frac{c_{xy}}{s_x s_y}} = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{x_i - \bar{x}}{s_x}\right)\left(\frac{y_i - \bar{y}}{s_y}\right).$$

つまり，**両方の変数を標準化した後の共分散**である．Y を正の定数 a 倍すると，共分散も s_y も a 倍になるので，r は変わらない．

相関係数の範囲は

$$\boxed{-1 \le r \le 1}.$$

r の符号は相関の向きを，絶対値 $|r|$ は**直線的な関係の強さ**を表す．

(1) $r = 1$ なら全点が右上がりの 1 本の直線上に，$r = -1$ なら全点が右下がりの 1 本の直線上にある．

(2) 逆も成り立つ．

$r = 0$ のときを**無相関**という．

範囲の証明．標準化した値を $u_i = (x_i - \bar{x})/s_x$，$w_i = (y_i - \bar{y})/s_y$ とおくと，

$$\frac{1}{n}\sum_{i=1}^{n}(u_i \pm w_i)^2 = 1 \pm 2r + 1 = 2 \pm 2r \ge 0.$$

よって，$2 + 2r \ge 0$ かつ $2 - 2r \ge 0$ より，$-1 \le r \le 1$． □

【例 3】 データ A の相関係数を求める．前節の表から，

$$v_x = \frac{56}{6} = \frac{28}{3}, \qquad v_y = \frac{56}{6} = \frac{28}{3}, \qquad c_{xy} = 7$$

であるから，$s_x = s_y = \sqrt{28/3}$ である．したがって，

$$r = \frac{7}{\sqrt{28/3}\cdot\sqrt{28/3}} = \boxed{\frac{3}{4} = 0.75}.$$

正の直線的な関係が見られるが，すべての点が 1 本の直線上にあるわけではない．

【演習 3】 データ B の相関係数を求め，データ A と相関の向き・強さを比較せよ．

$v_x =$ 9.33　　$v_y =$ 9.33　　$c_{xy} =$ -4.67

$$r = \frac{-4.67}{\sqrt{9.33}\cdot\sqrt{9.33}} = -0.5$$

データ B の相関：

データ A との比較：

注意

- 無相関は「関係がない」という意味ではない．例えば，

  $$(x_i, y_i) = (-1, 1),\ (0, 0),\ (1, 1)$$

  では，$\bar{x} = 0$，$\bar{y} = 2/3$ であり，$c_{xy} = 0$，$r = 0$ となるが，$y_i = x_i^2$ という関係がある．
- 相関があっても，片方がもう片方の原因であるとは限らない．

4 回帰直線

X から Y のおよその値を予測するため，散布図に直線を当てはめる．このとき，X を**説明変数**，Y を**目的変数**という．直線を $\widehat{y} = ax + b$ とすると，x_i に対する**予測値**は $\widehat{y}_i = ax_i + b$ である．観測値と予測値との差

$$e_i = y_i - \widehat{y}_i = y_i - (ax_i + b)$$

を**残差**という．**縦方向のずれである残差の 2 乗の和**

$$Q(a,b) = \sum_{i=1}^{n} \{y_i - (ax_i + b)\}^2$$

を最小にする方法を**最小二乗法**といい，それによって定まる直線を **Y の X への回帰直線**という．

$v_x > 0$ のとき，傾き a と切片 b は一意に定まり，

$$\boxed{a = \frac{c_{xy}}{v_x}, \qquad b = \bar{y} - a\bar{x}} \qquad (s_y > 0 \text{ なら } a = r\frac{s_y}{s_x}).$$

したがって，回帰直線は必ず点 $(\bar{x}, \bar{y})$ を通る．

証明. $y_i - ax_i - b = (y_i - \bar{y}) - a(x_i - \bar{x}) + (\bar{y} - a\bar{x} - b)$ を 2 乗して平均すると，偏差の和 $= \sum_i (x_i - \bar{x}) = \sum_i (y_i - \bar{y}) = 0$ であることから，

$$\begin{aligned} \frac{Q(a,b)}{n} &= v_y - 2ac_{xy} + a^2 v_x + (\bar{y} - a\bar{x} - b)^2 \\ &= v_x \left(a - \frac{c_{xy}}{v_x}\right)^2 + (\bar{y} - a\bar{x} - b)^2 + v_y - \frac{c_{xy}^2}{v_x}. \end{aligned}$$

最後の項は a, b に依存しないので，2 つの平方の項をともに 0 にすればよい． □

【例 4】 データ A の回帰直線と，$x = 7$ のときの予測値・残差を求める．

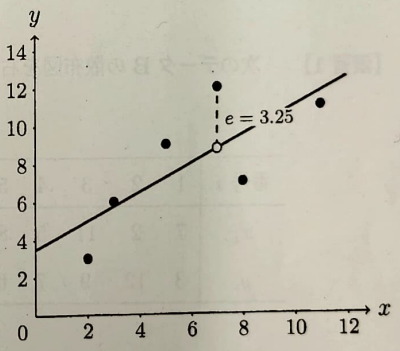
$\bar{x} = 6$, $\bar{y} = 8$, $v_x = 28/3$, $c_{xy} = 7$ より，

$$a = \frac{7}{28/3} = \frac{3}{4}, \qquad b = 8 - \frac{3}{4} \cdot 6 = \frac{7}{2}.$$

したがって，回帰直線は

$$\boxed{\widehat{y} = \frac{3}{4}x + \frac{7}{2}}.$$

$x = 7$ のとき，予測値は $\widehat{y} = 35/4 = 8.75$．観測値は $y = 12$ なので，残差は $e = 12 - 8.75 = 3.25$ となる．



【演習 4】 データ B の Y の X への回帰直線を求めよ．また，$x = 7$ のときの予測値と，その観測値 $y = 3$ に対する残差を求めよ．

注意 観測した x の範囲から大きく外れた値への予測や，散布図が曲線状なのに直線で予測することには注意が必要である．

A と B の和事象 $A \cup B = \{2,3,4,5,6\}$.

確率統計 I 第 4 回
確率

1 事象と試行

試行・事象などの言葉を以下のように使う．また，事象・全事象は集合で表すことができるのでそれも併記する．

試行 サイコロを投げて出た目を調べる．

事象 「素数の目が出た」$\to \{2,3,5\}$，「3 が出た」$\to \{3\}$, etc...

根元事象 「1 が出た」$\to \{1\}$，「2 が出た」$\to \{2\}$，etc...

全事象 「1 から 6 までの値が出た」$\to \{1,2,3,4,5,6\}$

試行 3 枚のコインを投げて，出た面を調べる．(表 $\to$ H，裏 $\to$ T)

事象 「全て表が出た」$\to \{(\mathrm{H},\mathrm{H},\mathrm{H})\}$,「裏がちょうど 1 回」$\to \{(\mathrm{H},\mathrm{H},\mathrm{T}),(\mathrm{H},\mathrm{T},\mathrm{H}),(\mathrm{T},\mathrm{H},\mathrm{H})\}$, etc...

根元事象 「表，表，裏の順に出た」$\to \{(\mathrm{H},\mathrm{H},\mathrm{T})\}$, etc...

全事象 $\{(\mathrm{H},\mathrm{H},\mathrm{H}),(\mathrm{H},\mathrm{H},\mathrm{T}),(\mathrm{H},\mathrm{T},\mathrm{H}),(\mathrm{H},\mathrm{T},\mathrm{T}),(\mathrm{T},\mathrm{H},\mathrm{H}),(\mathrm{T},\mathrm{H},\mathrm{T}),(\mathrm{T},\mathrm{T},\mathrm{H}),(\mathrm{T},\mathrm{T},\mathrm{T})\}$

即ち，

試行 ・・・観測や実験

事象 ・・・試行によって起こる結果の集まり

根元事象 ・・・一つの結果だけからなる事象

全事象 ・・・起こりうる全ての結果を集めた事象

また，要素を持たない事象 $\emptyset$ を**空事象**という．

今回，全事象が有限であるものを扱う．よって，扱う全ての事象は有限集合とみなせる．

Ω を全事象とする．事象 $A, B \subset \Omega$ について，

積事象： $A \cap B = \{x \mid x \in A \text{ かつ } x \in B\}$.

和事象： $A \cup B = \{x \mid x \in A \text{ または } x \in B\}$.

余事象： $A^c = \{x \in \Omega \mid x \notin A\}$.

A と B は 排反： $\iff$ $A \cap B = \emptyset$, 即ち， A と B は同時に起こり得ない.

事象 A の要素数： $n(A)$

【例 1】 サイコロを投げる試行について，

- A を 出目が 3 以上である事象,
- B を 出目が素数である事象とする.

この時，集合の外延的記法で表すと，$A = \{3,4,5,6\}$, $B = \{2,3,5\}$ である．またこの時，

全事象 $\Omega = \{1,2,3,4,5,6\}$.

A と B の積事象 $A \cap B = \{3,5\}$.

A と B の和事象 $A \cup B = \{2,3,4,5,6\}$.

A の余事象 $\overline{A} = \{1,2\}$.

排反事象の例 $\{1,3,4\}$ と $\{2,6\}$.

A の要素数 $n(A) = n(\{3,4,5,6\}) = 4$.

【演習 1】 数字 1,2,3,4,5 がそれぞれ書かれた 5 枚のカードから 2 枚引く試行を考える.

(1) 引いたカードの数字の和が 5 以下である事象を A とする. A と $\overline{A}$ を外延的記法で表せ.

$A = \{\{1,2\}, \{1,3\}, \{1,4\}, \{2,3\}\}$ $\overline{A} = \{\{1,5\}, \{2,4\}, \{2,5\}, \{3,4\}, \{3,5\}, \{4,5\}\}$

(2) 引いたカードの数字がどちらも 3 以上である事象を B とする. B と $A \cap B$ を外延的記法で表せ.

$B = \{\{3,4\}, \{3,5\}, \{4,5\}\}$, $A \cap B = \{\emptyset\}$

2 確率

試行をした時, 事象 A の起こりやすさを 0 以上 1 以下の数で表したものを**確率**と言い, $P(A)$ と書く.

!!! P には必ず集合を代入する !!!

例えば, (ちゃんとした) サイコロを振った時,

- 3 以下の目が出るという事象 $A = \{1,2,3\}$ の確率は $P(A) = \dfrac{1}{2}$ である.
- 3 の目が出るという事象 $B = \{3\}$ は根元事象であり, その確率は $P(B) = \dfrac{1}{6}$ である.
- 7 以上の目が出るという事象は空事象 $\emptyset$ であり, その確率は $P(\emptyset) = 0$ である.
- 1 以上の目が出るという事象は全事象 Ω であり, その確率は $P(\Omega) = 1$ である.

この例では, 全ての根元事象に対して, その確率は等しく $\dfrac{1}{6}$ である:

$$P(\{1\}) = P(\{2\}) = P(\{3\}) = P(\{4\}) = P(\{5\}) = P(\{6\}) = \frac{1}{6}$$

事象 A,B について, その確率が等しい, 即ち $P(A) = P(B)$ の時, A と B は**同様に確からしい**という.

ある試行の根元事象が全て同様に確からしいとき,

$$P(A) = \frac{n(A)}{n(\Omega)}$$

が成り立つ.

【例 2】 [例題 3.1]

2 つのサイコロを同時に投げる時, 次の事象が起こる確率を求めよ.

(1) 目の和が 7 となる事象 A.

$n(\Omega) = (2\text{ つのサイコロを投げた時の出目の組の場合の数}) = 6 \cdot 6 = 36.$

$n(A) = n(\{(1,6),(2,5),(3,4),(4,3),(5,2),(6,1)\}) = 6.$ よって, $P(A) = \dfrac{n(A)}{n(\Omega)} = \dfrac{1}{6}$

(2) 目の和が 8 となる事象 B.

$n(B) = n(\{(2,6),(3,5),(4,4),(5,3),(6,2)\}) = 5.$ よって, $P(B) = \dfrac{5}{36}$

【演習 2】 [問 3.3]

(1) 目の和が 5 となる事象 A

$A = \{(1,4),(2,3),(3,2),(4,1)\}$ $P(A) = \dfrac{4}{36} = \dfrac{1}{9} = 0.1$

(2) 2 つのサイコロの目がどちらも偶数となる事象 B.

$P(\overline{B}) = \dfrac{3}{4}$ $P(B) = \dfrac{1}{4}$ $P\{(\text{奇}, \text{奇})\} = \dfrac{1}{2}$

$P\{(\text{偶}, \text{偶})\} = \dfrac{1}{4}$

3 確率の性質

Ω が有限であることを仮定していたことを思い出そう．確率は以下の基本原理 (実は定義) を満たす：

【定理 1】

(1) $0 \leq P(A) \leq 1$

(2) $P(\emptyset) = 0$, $P(\Omega) = 1$

(3) $P(\overline{A}) + P(A) = 1$

(3) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

- 特に，A と B が排反 ($A \cap B = \emptyset$) の時，
  $P(A \cup B) = P(A) + P(B)$

【例 3】 [例題 3.2] 1 から 100 までの数字が書かれた 100 枚のカードから 1 枚のカードを引く時，

- A・・・引いたカードの数字が 3 の倍数である事象
- B・・・引いたカードの数字が 5 の倍数である事象

とする．$n(\Omega) = 100$ である．以下の事象の確率を求めよう．

(1) A・・・$n(A) = n(\{3k \mid 1 \leq k \leq 33\}) = 33$ より，$P(A) = \dfrac{33}{100}$

(2) B・・・$n(B) = n(\{5k \mid 1 \leq k \leq 20\}) = 20$ より，$P(B) = \dfrac{20}{100} = \dfrac{1}{5}$

(3) $A \cap B$・・・これは 3 の倍数かつ 5 の倍数である事象，即ち 15 の倍数である事象だから，$n(A \cap B) = n(\{15k \mid 1 \leq k \leq 6\}) = 6$ より，$P(A \cap B) = \dfrac{6}{100} = \dfrac{3}{50}$.

(4) $A \cup B$・・・3 の倍数または 5 の倍数... これは数えづらい！性質を使おう．

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) = \frac{33 + 20 - 6}{100} = \frac{47}{100}$$

(5) $\overline{A \cup B}$・・・「3 の倍数または 5 の倍数」でない，即ち 3 の倍数でも 5 の倍数でもない事象... やはり数えづらいので性質を使おう．

$$P(\overline{A \cup B}) = 1 - P(A \cup B) = \frac{100 - 47}{100} = \frac{53}{100}.$$

【演習 3】 [問 3.4] 1 から 8 までの数字が書かれた 8 枚のカードから 2 枚を同時に取り出すとき，取り出した 2 枚のカードの数の積が奇数となる事象を A, 取り出した 2 枚のカードの数の和が 6 の倍数となる事象を B とする．次の確率を求めよ：

(1) $A = \{\{1,3\},\{1,5\},\{1,7\},\{3,5\},\{3,7\},\{5,7\}\}$

$n(A) = {}_4C_2 = 6$

$n(\Omega) = {}_8C_2 = 28$

$P(A) = \frac{6}{28} = \frac{3}{14}$

(2) $B = \{\{1,5\},\{2,4\},\{4,8\},\{3,7\}\}$

$n(B) = 4$

$P(B) = \frac{4}{28} = \frac{1}{7}$

(3) $A \cap B = \{\{1,5\},\{5,7\}\}$

$n(A \cap B) = 2$

$P(A \cap B) = \frac{2}{28} = \frac{1}{14}$

(4) $A \cup B =$

$P(A \cup B) = P(A) + P(B) - P(A \cap B)$

$= \frac{3}{14} + \frac{2}{14} - \frac{1}{14} = \frac{4}{14} = \frac{2}{7}$

(5) $\overline{A \cup B} = \overline{A} \cap \overline{B}$

$1 - \frac{2}{7} = \frac{5}{7}$

問題設定が与えられた時，何を試行の結果と定めるか，注意が必要である．$P(A)=\dfrac{n(A)}{n(\Omega)}$ を使いたいなら，**全ての根元事象が同様に確からしいものを結果とする**．

【例 4】 [例題 3.3]1 つの袋に白玉が 6 個，赤玉が 4 個入っている．この袋から 4 個の玉を取り出す．

(1) 4 個とも白玉が出る確率は？

「玉を全て区別し，取り出す順番は区別しない」ものを結果とする．よって全事象 Ω は 10 個の区別された玉から 4 つ選ぶ事象であるから，$n(\Omega)={}_{10}\mathrm{C}_4=210$．そのうち，4 つとも白玉である事象の要素数は，白玉 6 つから 4 つ選ぶ場合の数だから，${}_6\mathrm{C}_4=15$．よって確率は $\dfrac{15}{210}=\dfrac{1}{14}$

(2) 白玉と赤玉が 2 個ずつ出る確率は？

同様に，この事象の要素数は，白玉 6 個から 2 つ，赤玉 4 個から 2 つ選ぶ場合の数だから，${}_6\mathrm{C}_2\cdot{}_4\mathrm{C}_2=90$．よって確率は $\dfrac{90}{210}=\dfrac{3}{7}$．

(3) 赤玉が少なくとも 1 個出る確率は？

「赤玉が少なくとも 1 個出る」という事象は「4 個とも白玉が出る」という事象 (確率 1/14) の余事象であるから，その確率は $1-\dfrac{1}{14}=\dfrac{13}{14}$．

(1) の別解例

「玉を全て区別し，取り出す順番も区別する」$n(\Omega)={}_{10}\mathrm{P}_4$．そのうち，白玉 4 つは ${}_6\mathrm{P}_4$．よって確率は $\dfrac{6\cdot5\cdot4\cdot3}{10\cdot9\cdot8\cdot7}=\dfrac{1}{14}$

(1) の誤答例「同色の玉は区別せず，取り出す順番も区別しない」全事象は，

$$\Omega=\{(\text{白 4 つ}),(\text{白 3 つ, 赤 1 つ}),(\text{白 2 つ, 赤 2 つ}),(\text{白 1 つ, 赤 3 つ}),(\text{赤 4 つ})\}$$

よって $n(\Omega)=5$．また全て白玉である事象は　$\{(\text{白 4 つ})\}$ なので，要素数は 1．

よって，確率は $\dfrac{1}{5}$　← ここが間違い！根元事象が同様に確からしくないので．

【演習 4】 [問 3.5] 1 つの袋に赤玉が 4 個，黒玉が 8 個入っている．この袋から同時に 2 個の玉を取り出す時，次の確率を求めよ．

(1) 2 個とも赤玉が出る確率　事象 A

$n(\Omega)={}_{12}\mathrm{C}_2=66$　$n(A)={}_4\mathrm{C}_2=6$　$P(A)=\dfrac{n(A)}{n(\Omega)}=\dfrac{6}{66}=\dfrac{1}{11}$

(2) 黒玉が少なくとも 1 個は出る確率　事象 B

$B=\overline{A}$　$\therefore P(B)=1-P(A)=\dfrac{10}{11}$

(3) 同じ色の玉が出る確率　事象 C　2 個とも黒：事象 D

$C=A\cup D$　$A\cap D=\{\emptyset\}$ なので，$P(C)=P(A)+P(D)$

$n(D)={}_8\mathrm{C}_2=28$　$P(D)=\dfrac{28}{66}$

$P(C)=\dfrac{6}{66}+\dfrac{28}{66}=\dfrac{34}{66}=\dfrac{17}{33}$

【演習 5】　子供 2 人，大人 2 人が円形に並ぶとき，子供が隣り合う確率を求めよ．　事象 A

(暗黙の仮定：各個人を区別したときのどの円順列も同様に確からしい)

$A=\{(C_1,C_2),(A_1,A_2)\}$

$A_1-A_2:0$

$C_2<A_2-A_1:0$

$C_1<A_1<C_2-A_2:Y$

$A_2<A_2-C_2:0$

$C_2-A_1:Y$

$A_1-C_2:0$

$P(A)=\dfrac{4}{6}=\dfrac{2}{3}$

確率統計 I 第 5 回
確率：反復試行・条件付き確率と乗法定理

1 試行の独立性と反復試行

【例 1】 [独立な試行と反復試行] 1 つのサイコロを 5 回投げる試行 T を考える.

T_n を n 回目のサイコロ投げの試行とする.

例えばすでにサイコロを 3 回投げる試行 T_1, T_2, T_3 をしている時，それらがどのような結果であっても，4 回目のサイコロを投げる試行 T_4 の結果には何ら影響を与えない.

このように，試行 $T_1, \ldots, T_5$ が互いの結果に影響を与えないとき，試行 $T_1, \ldots, T_5$ を**独立**という.

独立な試行 $T_1, \ldots, T_5$ を繰り返し行う試行 T を，**反復試行**という.

【例 2】 [反復試行の確率] サイコロを 3 回振る時，以下の事象を A とする：

- A_1：1 回目は偶数 (3 通り)
- A_2：2 回目は 3 が出る (1 通り)
- A_3：3 回目は 5 か 6 が出る (2 通り)

確率 $P(A)$ を求めよう．全事象 Ω について，$n(\Omega) = 6 \cdot 6 \cdot 6$ である．また事象 A について，$n(A) = 3 \cdot 1 \cdot 2$ である．よって，$P(A) = \dfrac{3 \cdot 1 \cdot 2}{6 \cdot 6 \cdot 6} = \dfrac{1}{36}$.

観察：$P(A) = \dfrac{3 \cdot 1 \cdot 2}{6 \cdot 6 \cdot 6} = \dfrac{3}{6} \cdot \dfrac{1}{6} \cdot \dfrac{2}{6} = P(A_1) \cdot P(A_2) \cdot P(A_3)$ である.

定理 1.1: 反復試行の確率

n 回の反復試行において，「i 回目の結果が事象 A_i に属する」事象 A について，

$$P(A) = P(A_1) \cdot P(A_2) \cdot \cdots \cdot P(A_n) = \prod_{i=1}^{n} P(A_i)$$

特に，反復の各試行が全て事象 B に属する事象 A について，

$$P(A) = P(B)^n$$

【演習 1】

(1) サイコロを 4 回投げる時，n 回目の出目が n 以上である確率を求めよ.

$\frac{6}{6} \times \frac{5}{6} \times \frac{4}{6} \times \frac{3}{6} = \frac{5}{18}$

(2) コインを 5 枚投げる時，一度は表が出る確率を求めよ.

$1 - \frac{1}{2^5} = \frac{31}{32}$

【例 3】 1つのサイコロを5回投げる時，3の倍数の目がちょうど2回出る確率は？

全事象 $\Omega = \{(1,1,1,1,1),(1,1,1,1,2),\ldots,(6,6,6,6,5),(6,6,6,6,6)\}$・・・$n(\Omega) = 6^5$.

3の倍数の目がちょうど2回でる事象を A とおく．i,j 回目が3の倍数，それ以外は3の倍数でない目が出る事象を A_{ij} とおく．例えば，

$$\begin{aligned} A_{12} = \{&(3,3,1,1,1),(3,3,1,1,2),(3,3,1,1,4),\ldots,(3,3,5,5,5),\\ &(3,6,1,1,1),(3,6,1,1,2),(3,6,1,1,4),\ldots,(3,6,5,5,5),\\ &(6,3,1,1,1),(6,3,1,1,2),(6,3,1,1,4),\ldots,(6,3,5,5,5),\\ &(6,6,1,1,1),(6,6,1,1,2),(6,6,1,1,4),\ldots,(6,6,5,5,5)\} \end{aligned}$$

この時，

- どの $1 \le i < j \le 5$ についても，$n(A_{ij}) = 2^2 \cdot 4^3$
- $1 \le i < j \le 5$ となる $\{i,j\}$ の個数 (何回目に3の倍数が出るかの場合の数) は，${}_5\mathrm{C}_2$

よって，
$$n(A) = \sum_{1 \le i < j \le 5} n(A_{ij}) = {}_5\mathrm{C}_2 \cdot 2^2 \cdot 4^3$$

であるから，求める確率は，
$$\frac{n(A)}{n(\Omega)} = {}_5\mathrm{C}_2 \cdot \frac{2^2 \cdot 4^3}{6^5} = {}_5\mathrm{C}_2 \cdot \left(\frac{2}{6}\right)^2 \cdot \left(\frac{4}{6}\right)^3 = \frac{80}{243}$$

観察： $p = \dfrac{1}{3}$，即ち，1回サイコロを振った時に3の倍数が出る確率とすると，

$${}_5\mathrm{C}_2 \cdot \left(\frac{2}{6}\right)^2 \cdot \left(\frac{4}{6}\right)^3 = {}_5\mathrm{C}_2 \cdot p^2 \cdot (1-p)^3$$

定理 1.2: 反復試行の確率

1回の試行において事象 A の確率が p である時，n 回の反復試行において，事象「A がちょうど k 回起こる」の確率は

$${}_n\mathrm{C}_k \cdot p^k \cdot (1-p)^{n-k}$$

【演習 2】 1枚の硬貨を5回投げる時，表がちょうど3回出る確率を求めよ．

【演習 3】 ある工場で製造される製品は，1個につき独立に確率 0.2 で不良品となる．7個の製品を製造したとき，次の確率を求めよ．

(1) 不良品がちょうど3個となる確率．

(2) 不良品が3個以下となる確率．

2 条件付き確率

ある試行の全事象 Ω 上に確率 P が与えられているとする．全事象を事象 $A \subset \Omega$ に限定し新たな確率を考える．

定義 2.1: 条件付き確率

事象 $A, B \subset \Omega$ について，$P(A) \neq 0$ の時，

$$P(B|A) := \frac{P(A \cap B)}{P(A)} \tag{1}$$

を，事象 A を条件とする B の**条件付き確率**という．

$P(B|A)$ は，事象 A が起こったという条件のもと，B が起こる確率を表す．根元事象が全て同様に確からしい時，

$$P(B|A) := \frac{n(A \cap B)}{n(A)} \tag{2}$$

となる．

【例 4】 1 万人のうち 100 人がある感染症に感染しているとする．検査によって，感染者のうち 99% が陽性，非感染者のうち 1% が陽性と診断された．

陽性と診断された時，感染症にかかっている確率は，

$$P((\text{感染していて陽性})|(\text{陽性})) = \frac{99/10000}{(99+99)/10000} = \frac{1}{2}$$

【演習 4】 ある学校の 1 年生は 200 人で，そのうち女子は 45 人である．2 年生は 208 人で，そのうち女子は 48 人である．2 つの学年を合わせた 408 人の中から，無作為に一人を選ぶ時，次の確率を求めよ．

(1) 選ばれた学生が女子である確率，および選ばれた学生が 2 年生の女子である確率

(2) 選ばれた学生が女子であった時，この学生が 2 年生である確率

(3) 選ばれた学生が男子であった時，この学生が 1 年生である確率

3 確率の乗法定理

条件付き確率の定義を変形しただけだが，非常に有用である．

定理 3.1: 確率の乗法定理

$P(A) \neq 0$ かつ $P(B) \neq 0$ の時，

$$P(A \cap B) = P(A)P(B \mid A) = P(B)P(A \mid B)$$

【例 5】 10 本のくじの中に 4 本の当たりがある．このくじを 2 人が順に一本ずつ引く．次のようにくじを引く時，1 人目の当たる確率，および 2 人目の当たる確率を求めよ．

(1) 1 人目が引いたくじを戻す場合（**復元抽出**）

H_i を i 人目が当たる事象とする．この状況では，$P(H_1) = P(H_2) = \dfrac{2}{5}$．

(2) 1 人目が引いたくじを戻さない場合（**非復元抽出**）

1 人目が当たる確率は同じく $P(H_1) = \dfrac{2}{5}$．2 人目が当たる確率を求めよう．確率の基本性質から，

$$P(H_2) = P(H_2 \cap H_1) + P(H_2 \cap \overline{H}_1)$$

確率の乗法定理から，

$$P(H_2 \cap H_1) = P(H_1) \cdot P(H_2 \mid H_1) = \frac{2}{5} \cdot \frac{3}{9} = \frac{2}{15}.$$

$$P(H_2 \cap \overline{H}_1) = P(\overline{H}_1) \cdot P(H_2 \mid \overline{H}_1) = \frac{3}{5} \cdot \frac{4}{9} = \frac{4}{15}.$$

よって，$P(H_2) = \dfrac{2}{15} + \dfrac{4}{15} = \dfrac{6}{15} = \dfrac{2}{5}$．（よく考えれば当たり前である）

【演習 5】 ある地域では，雨が降る日が全体の 0.4 を占める．晴れとは，雨でないことをいうこととする．

(1) 学生 a の遅刻する確率は，雨の時 0.2，晴れの時 0.05 である．無作為に 1 日を選ぶ時，学生 a が遅刻する確率を求めよ．

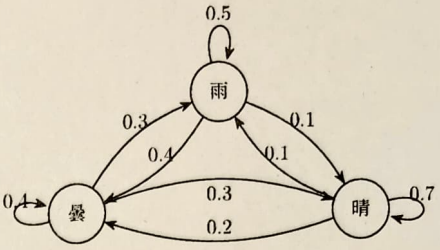
(2) 天気予報は，雨の時も晴れの時も 0.8 の確率で正しく予報するとする．無作為に 1 日を選ぶ時，天気予報が雨と予報する確率を求めよ．[*1]

(予告) 雨の予報の時，学生 a の遅刻する確率はどうなるだろうか．そもそも確率が定まるだろうか．

[*1] 「天気予報は 0.8 の確率で正しい予報をする」では天気予報が雨と予報する確率は定まらない．

確率統計 I 第 5 回　余談：独立でない試行

ある日から n 日目の天気を観測する試行を T_n とする．結果は雨・曇り・晴れのどれかとしよう．$T_1, T_2, \ldots, T_n, \ldots$ は独立とみなすのは不適切である．なぜなら，T_1 の結果が雨である時，T_2 の結果も雨である確率が高いと予想されるからだ．一方，T_{n+1}（明日の天気）の結果それぞれの確率は T_n（今日の天気）の結果のみから決まると考えることは，（独立だと考える場合と比較して）妥当だと考えられる．次の試行 T_{n+1} の結果それぞれの確率が，T_n の結果**のみ**によって決まる時，この繰り返しの試行をマルコフ連鎖といい，下のような図で表される．



例えば晴れが曇りになる確率は 0.2 である，と読む．このようにある状態から次の状態に遷移するそれぞれの確率を遷移確率という．反復試行とは，言い換えれば遷移確率が現在の状態に依存せず，遷移先の状態のみに依存するマルコフ連鎖である．

線形代数で学習した行列と固有ベクトルを用いて，十分先の天気の確率を求めることができる．

雨・曇・晴をそれぞれ状態 1, 2, 3 とし，状態 j から状態 i に遷移する確率を p_{ij} とする．この時，遷移行列 $P = (p_{ij})$ は

$$P = \begin{pmatrix} 0.5 & 0.3 & 0.1 \\ 0.4 & 0.4 & 0.2 \\ 0.1 & 0.3 & 0.7 \end{pmatrix}$$

となる．各列の成分の和は 1 である．

n 日目の天気が雨・曇・晴である確率をそれぞれ r_n, c_n, s_n とし，

$$\boldsymbol{v}_n = \begin{pmatrix} r_n \\ c_n \\ s_n \end{pmatrix}$$

とおく．この時，

$$\boldsymbol{v}_{n+1} = P\boldsymbol{v}_n$$

今回のように P の成分が全て正である場合，$n \to \infty$ の時，$\boldsymbol{v}_n$ は初日の天気の確率分布によらず，あるベクトル $\boldsymbol{q}$ に収束する．この $\boldsymbol{q}$ は，

$$P\boldsymbol{q} = \boldsymbol{q}, \qquad q_1 + q_2 + q_3 = 1$$

を満たす確率ベクトルである．つまり，$\boldsymbol{q}$ は固有値 1 に属する固有ベクトルを成分の和が 1 となるように正規化したものである．実際に計算すると，$\boldsymbol{q} = \begin{pmatrix} 6/22 \\ 7/22 \\ 9/22 \end{pmatrix}$ となる．

また，今回の天気のように，反復試行と考えると不適切，マルコフ連鎖と考えるとまだマシ，といったように，一つの現象に対して複数の確率の数学的な枠組みを考えることができる．現象の確率的な振る舞い (晴れの確率) を表現するための，数学的な確率の枠組み（反復試行，マルコフ連鎖）を確率モデルという．